

已知总时长与同段信息共享下的分段运行时间估计

Abstract—公交运行分析需要定位耗时较长的站间区间,但稀疏观测往往只覆盖整趟行程及少量局部位置。已知运行总时长不能唯一确定各区间耗时,相同区间在不同行程中也存在差异。**Ours** 结合重复区间共享估计与有界行程修正,再按已知总时长进行比例缩放。在公开 Astana 公交数据开发集上比较三种局部标签预算。在验证集选出的主比较中,**Ours** 的 MAE 点估计在 1% 和 5% 预算下低于同输入直接预测,分别相差 0.579 秒和 0.075 秒;在 10% 预算下则更高。九组配对运行中,**Ours** 分别在 8、6 和 0 组取得较低误差。标签极少时,同段均值仍优于 **Ours**。通过验证集选择 0.5 权重的 **Ours+Direct** 集成在三种预算下均低于直接预测,但它是独立的集成预测器,且 1% 预算下仍不及同段均值。相同标签数量在不同区间覆盖布局下也产生不同误差。最终时间划分未参与评价,因此这些结果仅反映开发集比较。

Index Terms—分段运行时间估计,已知总时长,同段信息共享,稀疏监督,公交运行。

I. 引言

公交运营人员分析线路运行时,需要知道耗时发生在哪些站间区间。整趟行程的总时长可以用于比较线路效率,却不能说明某次延误主要发生在前段还是后段。分段运行时间能够支持瓶颈区间筛查和分时段运行比较。然而,完整局部记录依赖持续定位与可靠的站点匹配,设备采样间隔和记录缺失会使部分区间不可观测。利用已知总时长和有限局部观测估计各段时间,因而是旅行时间推断中的实际需求 [1]–[3]。

本文研究已经完成行程的分段运行时间估计。这里分段是有向站间区间,总时长是各区间运行时间之和,不包含停站时间。它与起终点时间戳之差有所区别:后者还可能包含停站和其他非运行时间,需要先分离这些部分并对齐区间边界。实验对公开数据的运行时间求和构造已知总时长,以考察精确总时长条件下的分段估计。

考虑一趟经过三个连续区间、运行总时长为十分钟的行程。(2, 3, 5) 和 (5, 3, 2) 分钟是两组可行分配。训练中即使提供中间区间三分的标签,也无法区分这两种分配;推理时不提供当前行程的局部标签。这两组结果分别将末段和首段识别为最耗时的位置,可能导致不同的运营判断。其他行程中相同区间的记录能够帮助区分这两种分配;但如果当前行程的出发时段或路线条件发生变化,直接沿用历史平均值又可能掩盖差异。这个例子说明,模型既需要利用同一区间的重复观测,也需要判断当前行程应如何偏离平均规律。

已有研究通过自由流信息、局部时间分布或统计交通流模型为总时长分解提供依据 [1], [2]。路径不完整时,路段推断还需联合估计经过的路径与局部时间 [3], [4]。本文关注路径顺序已知、区间重复出现且部分单区间标签可见的条件。这里不需要重新恢复路径,关键在于如何把跨行程可共享的信息与当前行程的差异结合起来,并保证分段输出符合已知总时长。

同段均值利用重复观测,却把随出发时段和行程条件变化的耗时视为固定值;本文的直接预测基线也共享区间嵌入并使用当前行程上下文,但直接输出正值分数,不设置

单独的重新分配分支。本文将两者分开建模:共享分支根据上下文估计基础时间,序列分支提出有界调整,随后按已知总时长比例缩放。本文的贡献是这一分配参数化及其在稀疏标签下的分析;其精度能否优于直接预测仍需由实验检验。

实验结果进一步限定了这一设计的作用。标签极少时,同段均值仍是有竞争力的基线;在较高标签预算下,本文方法改善了同段均值的误差,但对同输入直接预测没有稳定优势。关闭行程修正会使同一模型的误差上升,说明修正分支有助于基础估计,却不能据此推断完整方法优于直接预测。相同标签数量若只覆盖较少区间身份,误差会显著增加;在身份集合和逐身份标签数相同的控制中随机改变标签位置,也没有恢复较广覆盖时的精度。由此可见,已知总时长排除了不满足总量的分配,却不能单独判定哪一种局部时间分配正确;方法能否作出有用判断,还取决于共享区间信息的覆盖程度。

II. 相关工作

A. 已观测旅行时间的分解

稀疏探测车辆的两次位置观测可能跨越多个道路链路,因此需要沿已识别路径分配两次观测之间的耗时。Hellinga 等利用链路几何与自由流速度,将旅行时间分为自由流、拥堵和停止时间 [1]。其拥堵似然利用前一采样区间的信息,停止似然则反映车辆位置与链路下游端的关系,最终通过对可能的拥堵程度积分得到时间分配。Hofleitner 和 Bayen 从干道排队与驾驶行为的统计模型推导链路时间分布 [2]。这些分布由对数凹分量混合而成,整体分配问题并非凸问题;固定延迟模式后可得到凸子问题,进而采用枚举或基于 EM 的算法求解。两项研究均要求分配时间之和等于观测总时长。

网络层面的推断还可以结合多次行程的共同观测。Yin 等从行程进出记录推断链路时间分布,研究高斯似然、路径未知时的混合模型估计,以及面向更一般分布的行程拆分 [3]。PR-LTTE 交替利用行程距离与耗时恢复路径,并通过非负最小二乘估计链路时间 [4]。这些方法估计共享的道路链路量,部分方法还需恢复缺失路径。本文已知有序的有向公交站间区间,每个区间可以跨越多个道路链路;共享估计随可观测上下文变化,重新分配则随具体行程变化。NNLS-Ridge 参照用于检验这一已知序列条件下的固定区间身份系数。

B. 旅行时间表示学习

DeepTTE 结合地理卷积与循环网络,同时学习整条路径和局部路径的旅行时间 [5]。其局部标签来自 GPS 窗口的时间戳差,窗口之间可以重叠;整条路径时间由独立的注意力预测头输出。DutyTTE 针对未提供路线时的旅行时间不确定性,将预测路径对齐与上下文相关的区间不确定性建模结合起来 [6]。这类设计利用局部观测与路线表示预测尚未知晓的行程耗时。

ProbETA 与重复链路的信息共享更为接近 [7]。Xu 等将链路时间写为共享均值、日期随机效应和行程随机效应之和，通过学习低秩协方差表示描述行程之间和行程内部的依赖。训练利用行程总时间与时间戳生成的子行程时间构建联合似然，推断则结合邻近已完成行程，对查询行程的时间分布作条件估计。这是一种以概率模型组织共享链路证据的方式。本文已知查询行程的总时长，由有限单区间标签监督内部时间分配；行程修正的幅度相对于共享基础时间受到限制，并在本次行程内加和为零，其作用是调整分配比例。

C. 聚合监督与加和一致性

聚合观测学习研究如何根据组级监督估计个体标签。Zhang 等推导聚合观测的似然，并在条件独立假设下讨论由均值或总和监督进行回归 [8]。其中，聚合误差用于训练个体预测器。本文通过比例缩放使每次输出严格符合给定总量，因此最终输出的总和误差不提供学习信号。训练和模型选择分别使用训练集与验证集中的可见单区间标签。

预测协调从另一个角度处理加和一致性。MinT 利用预测误差协方差结合不同聚合层级的预测，使协调后的预测满足加和关系 [9]。本文的总量是已观测输入，需要学习的是未知的区间份额，随后将其缩放到该总量。相应地，实验在相同输入、标签预算和最终缩放下比较“共享基础估计加行程修正”与直接区间预测，检验施加一致性约束后如何学习行程内部的时间分配。

III. 方法

A. 任务定义

训练输入为有向站间区间序列、上下文特征及行程运行总时长，监督只使用可见的单区间标签。推理使用相同类型的输入，估计当前行程各区间的运行时间。本文的区间连接两个相邻站点，可能跨越多条道路边。重复区间通过共享参数利用其他行程的观测，同时保留不同出现之间的耗时差异。

行程 q 包含 L_q 个有序区间，第 i 个区间的身份、特征和运行时间分别为 s_{qi} 、 x_{qi} 和 $t_{qi} \geq 0$ ，已知运行总时长为 $T_q > 0$ 。将有序特征和身份记为 X_q ，模型输出满足

$$\hat{t}_q = f_\theta(X_q, T_q), \quad \hat{t}_q \geq 0, \quad \mathbf{1}^\top \hat{t}_q = T_q. \quad (1)$$

总时长与区间目标采用相同的时间定义和观测边界，当前行程的局部真值不作为推理输入。

训练时仅集合 V 中的单区间标签可见。若一趟行程有 $m < L_q - 1$ 个不同位置的标签，加上总时长方程后，在严格正值的可行解附近仍有 $L_q - m - 1$ 个自由方向。在两个未观测区间之间转移少量时间，就能保持现有观测不变。这正是引言中首尾分配难以区分的原因，也是利用同段观测和上下文学习分配规律的依据。

B. 总体设计

图1展示三个步骤：根据区间身份和上下文估计基础时间，读取有序行程调整各段的相对分配，再将预测分配归一到已知总时长。两个分支通过最终分段输出接受局部监督；总时长不作为编码特征。同段信息由训练中共享的参数积累，无需在推理时额外输入历史时间标签。

C. 共享表示与序列表示

模型为每个有效分量构造两类表示。共享表示 h_{qi}^B 由公共特征映射与身份嵌入组成，使相同身份的不同出现能够复用参数。序列表示 h_{qi}^R 在局部特征、身份与位置嵌入的基础上，加入有向邻接转移，再由 Transformer 处理有序序列。有效位置表示的均值经线性映射后回加到各位位置，并进行层归一化。所有阶段均屏蔽填充位置。

两个标量网络分别生成基础值与修正分数。令 I_q 为有效位置集合。省略序列下标，有

$$b_i = \exp(\text{clip}(g_B(h_i^B), -8, 12)), \quad (2)$$

$$u_i = g_R(h_i^R), \quad z_i = u_i - \frac{1}{|I_q|} \sum_{j \in I_q} u_j, \quad i \in I_q. \quad (3)$$

截断避免指数运算溢出， z_i 通过有效位置均值中心化。下一步再按基础比例中心化局部调整，以保证修正之和为零。由于共享特征包含日历等上下文， b_i 随条件变化，不是固定历史均值。

D. 有界重新分配

令 $B = \sum_j b_j$ 、 $p_i = b_i/B$ ，并取固定 $0 < \rho < 1/2$ ，定义

$$a_i = \rho b_i \tanh(z_i), \quad (4)$$

$$\delta_i = a_i - p_i \sum_j a_j, \quad r_i = b_i + \delta_i. \quad (5)$$

第一项提出上下文相关的局部变化，第二项按基础比例去除其中的总量变化。由于 $\sum_i p_i = 1$ ，可得 $\sum_i \delta_i = 0$ ，从而 $\sum_i r_i = B$ 。同时，

$$|\delta_i| \leq \rho b_i + p_i \rho B = 2\rho b_i, \quad (6)$$

因此

$$(1 - 2\rho)b_i \leq r_i \leq (1 + 2\rho)b_i. \quad (7)$$

有效位置的修正后取值始终为正。主比较根据可见验证标签为每个预算分别选择 ρ ；固定 $\rho = 0.45$ 的控制实验单独报告。将修正分数置零时， $\delta_i = 0$ ，只保留基础项。

幅度上界使行程调整保留与基础估计的联系，并直接保证正值；若基础估计偏差很大，这一上界也可能限制纠正能力。零和修正则去除行程分支的整体增减，使其专门处理各段之间的重新分配。最终缩放可以对任意正值向量保证加和一致，因此零和条件的作用是约束修正分支，而不是增加一个必要的守恒步骤。实验分别比较修正幅度及两种中心化形式，检验这些设计对误差的实际影响。

E. 已知总时长调整

基础估计的加和不一定等于已知总时长。本文采用比例缩放满足式(1)：

$$\hat{t}_i = T \frac{r_i}{\sum_j r_j} = T \frac{r_i}{B}. \quad (8)$$

等价地，

$$\hat{t}_i = T p_i \left[1 + \rho \left(\tanh z_i - \sum_j p_j \tanh z_j \right) \right]. \quad (9)$$

式(9)表明，基础估计与中心化修正决定行程内的比例， T 决定整体尺度。有效位置保持非负，填充位置为零；浮点求和的舍入残差加到最大有效分量。固定 X 并改变总时长只会等比例改变输出。Ours 与直接预测使用相同的最终调整，比较重点因而是局部分配，而非是否满足总时长。

Fig. 1. Ours 总体结构。共享分支估计正值基础时间，序列分支生成有界零和修正，已知行程总时长由比例缩放施加。

F. 可见局部标签学习

对于批次 $\mathcal{B}$ 中的可见训练位置 $V_{\mathcal{B}}$ ，最小化

$$\mathcal{L}_{\mathcal{B}} = \frac{1}{|V_{\mathcal{B}}|} \sum_{(q,i) \in V_{\mathcal{B}}} h_{\beta}(\hat{t}_{qi} - t_{qi}), \quad (10)$$

其中

$$h_{\beta}(e) = \begin{cases} e^2/(2\beta), & |e| < \beta, \\ |e| - \beta/2, & \text{其他}. \end{cases} \quad (11)$$

实验取 $\beta = 5$ 秒。比例调整使同一行程的各段预测相互关联，可见位置的误差通过公共分母回传到两条分支。不可见标签不参与目标计算。缩放后的总时长误差恒为零，不能单独用于学习分配，因此主实验使用局部 Huber 损失，无标签参考采用均匀分配。重新分配与缩放的计算量为 $O(L)$ ，宽度为 d 的自注意力计算量为 $O(L^2d)$ 。

G. 完整标签下的可选辅助目标

主实验只使用式(10)。报告的 Singapore 辅助运行禁用了历史侧路；在局部标签完整的条件下，另加入时长权重和前缀误差。若 $M_{qk} = 1$ 表示有效位置，前缀目标为

$$\mathcal{L}_P = \frac{\sum_{q,k} M_{qk} \left| \sum_{i \leq k} (\hat{t}_{qi} - t_{qi}) \right| / \max(T_q, 1)}{\sum_{q,k} M_{qk}}. \quad (12)$$

累计误差与归一化分母均只计有效区间，增加右侧填充不改变损失。辅助实验使用 $\mathcal{L}_W + \lambda_P \mathcal{L}_P$ ，其中 $\mathcal{L}_W$ 为按有效时长权重归一化的局部 Huber 损失。权重和训练配置见实验部分。额外历史标签条件下的同段对数时长目标在补充材料单独报告。

IV. 实验

主要比较采用 Astana 数据及相同局部损失和训练配置；Singapore 辅助实验使用完整局部标签评价前缀目标。

A. 数据、时间定义与预处理

Astana 数据集 [10] 于 2025 年 6 月 29 日在 Zenodo 发布，采用 CC BY 4.0 许可，采集描述覆盖 2024 年 7 月至 9 月三条公交线路。使用的站间记录覆盖 2024 年 7 月 29 日至 9 月 21 日，共 785,976 条记录和 19,769 趟行程。预处理要求有向站点链连续、运行时间为 5 至 1,800 秒、停站时间为 0 至 900 秒；不满足条件的行程整趟删除。最终保留 10,910 趟、439,659 个区间和 586 个有向区间身份。最长有效行程含 55 个区间，模型据此填充，未对更长行程截断。

TABLE I
ASTANA 分区与有效标签规模。

用途	行程数	有效区间数
模型拟合	5,891	237,203
检查点选择	655	26,561
开发评价	2,182	87,715

区间身份由方向、起点和终点站标识构成，目标采用记录中的运行时间字段。各有效区间目标之和构成输入总时长，停站时间不计入目标。

行程按时间排序后以 60%/20%/20% 划分。第一部分中 5,891 趟用于拟合、655 趟用于选择检查点；中间 20% 的 2,182 趟作为开发评价集。最后 20% 未纳入本文报告 (表I)。

模型使用 31 项几何、路线、站点和出发日历特征，标准化参数仅由拟合数据估计。输入排除目标衍生统计、真实区间进入时间、标签质量字段及额外历史时间标签。

Singapore 辅助数据覆盖 2017 年 5 月 5 日至 6 月 19 日。区间目标由相邻连续站点观测组的时间中点之差计算，未独立剥离停站时间。每个源记录取最长有效连续片段，要求至少 8 个区间、时长 30 至 1,800 秒、观测弦速度不超过 25 米/秒；最大长度 87，不插值或跨记录拼接。训练日期为 5 月 5 日至 6 月 5 日，检查点选择为 6 月 6 日至 8 日，开发评价为 6 月 10 日至 16 日，中间留一天。分别使用 50,000、5,000 和 10,000 趟行程，开发评价含 197,301 个区间。该数据的目标定义与 Astana 不同，故结果分开报告。

B. 标签预算与训练设置

训练与验证采用相同的标签比例，预算为 1%、5% 和 10%。训练分别开放 2,372、11,860 和 23,720 个标签，验证为 265、1,328 和 2,656 个。每个划分随机排列有效位置并按预算抽取，使用三组嵌套标签布局，每组进行三次独立初始化，因此每种神经网络方法在每个预算下有九次运行。两种方法共享配对初始化、批次和可见标签；不可见目标在训练及验证前屏蔽。

编码器宽度 64，含两层 Transformer 和四个注意力头，前馈宽度 256，dropout 为零。主 Ours/直接预测比较使用 AdamW，初始学习率 0.001 并采用余弦退火，训练 960 步，每 24 步检查一次。由验证集选择的修正幅度 ρ 在 1%、5%、10% 预算下分别为 0.10、0.05 和 0.25。覆盖与机制控制采用独立的 240 步协议：AdamW 学习率 0.003、权重衰减 10^{-4} 、梯度范数上限 5，每步 256 趟，并按随机排列循环取批次。日历/修正及修正参数化消融采用三组 10% 标签

布局, 每组进行三次配对初始化; 区间计数控制采用一组布局 and 三次初始化。开发指标使用开发评价集的全部局部标签。

Singapore 使用完整训练与检查点选择标签, 批次 2,048, 其他网络及优化配置相同。辅助局部权重为

$$w_{qi} = 1 + 0.75 \frac{t_{qi}}{\max(\bar{t}_q, 1)} + 1.5 \min \left(\frac{(t_{qi} - 180)_+}{180}, 5 \right), \quad (13)$$

其中 $\bar{t}_q$ 为有效区间平均时间, 权重按有效和归一化, 前缀系数为 0.35。这些目标依赖完整局部标签, 只用于辅助实验。额外历史条件在补充材料单独报告。

C. 比较方法与指标

均匀分配把 T_q/L_q 分给每段。同段均值汇总同一区间的可见训练标签, 未见区间使用可见标签的全局均值, 再缩放到总时长。NNLS-Ridge 为每个区间身份拟合非负系数 v_s , 目标为

$$\min_{v \geq 0} \frac{\|Cv - T\|_2^2}{N_F} + \frac{\lambda}{S} \|v\|_2^2 + \frac{\alpha}{N_V} \sum_{(q,i) \in V} (v_{sqi} - t_{qi})^2, \quad (14)$$

其中 C 为行程内各区间的计数矩阵, N_F 、 N_V 和 S 分别为训练行程数、可见标签数和区间身份数。十组候选由 $\lambda \in \{0.01, 1\}$ 和 $\alpha \in \{0, 1, 10, 100, 1000\}$ 组成, 依据同一有限验证标签选参; 预测按总时长缩放。这一基线检验不使用上下文的非负聚合反演。

直接预测使用相同特征和序列骨干, 通过局部对数时长与路线比例映射生成正值分数, 再执行相同的总时长缩放, 不设置基础加修正结构。两种方法实例化相同参数并共享初始化, 实际计算与梯度路径随预测形式变化。ProbETA 适配模型使用作者代码 [7], 通过可见单区间的高斯似然训练, 再以已知总时长求条件非负解; 由于输入与损失不同, 其结果及训练预算检查单独报告。

总体指标为有效区间微平均 MAE、RMSE 与 WAPE(%) = $100 \sum |\hat{t} - t| / \sum_q T_q$ 。Prefix50 先计算每趟前 $\lceil L_q/2 \rceil$ 段累计误差的绝对值, 再跨行程平均。高贡献 10% MAE 取每趟真实值最大的 $\lceil 0.1L_q \rceil$ 段; 长区间定义为真实运行时间至少 300 秒, 标签仅用于评价分组。

表格报告重复运行的误差均值与样本标准差。最终时间划分未参与评价。

D. 总体结果

每种神经方法在每个预算下均进行九次配对运行, 使用相同的三组标签布局与三次初始化。ExtraTrees 在验证集上选择叶节点最小样本数 2、8 和 8, 并在三个布局上评价。同段均值与 NNLS-Ridge 按各预算下可见标签拟合。表中的 Ours+Direct 为验证集选出的固定权重集成 ($\alpha = 0.5$), 并非 Ours 单模型。

1% 预算下, 同段均值 MAE 最低, 为 31.498 秒; Ours 为 32.607 秒, 直接预测为 33.186 秒。5% 预算下, Ours 为 29.383 秒, 比直接预测的 29.457 秒低 0.075 秒, 九组配对运行中有六组 Ours 误差较低; 集成结果为 28.783 秒。10% 预算下, Ours 为 28.776 秒, 比直接预测的 28.481 秒高 0.295 秒, 九组配对运行中没有一组 Ours 更低, 集成为 28.065 秒。集成在 5% 和 10% 下取得最低平均 MAE, 但

1% 下同段均值仍更低; Ours 在三个预算下的长区间 MAE 均较高。现有开发集结果不能证明 Ours 在不同预算或指标上具有一致优势。

图2报告各布局相对直接预测的 MAE 差。Ours 在 1%、5%、10% 下分别有 8/9、6/9 和 0/9 组配对运行误差更低 (表III)。图中神经方法先在每个布局内对三次初始化取均值, 误差线表示三个布局间的样本标准差。该图仅概括开发集比较, 不代表独立测试结果。

三个预算下, Ours 的长区间 MAE 均高于直接预测 (表II), 尽管两者都严格满足总时长约束。因此, 个别长区间的误差可能被准确的行程总和掩盖。

E. 标签数量与覆盖范围

标签预算首先改变可学习信息的数量, 但相同数量也可能覆盖不同区间。完整验证标签的布局实验中, 将 23,720 个训练标签限制在每趟前 20% 后, 可见区间身份从 301 降为 115 个, 本文方法 MAE 由 28.522 增至 50.121 秒; 随机移动 40% 连续遮挡保留 310 个身份, MAE 为 28.774 秒。前缀布局同时改变位置和区间覆盖, 原比较无法识别位置的独立作用。该实验完整结果在补充材料中报告。

为进一步区分这两种变化, 采用主实验的有限验证设置, 固定前 20% 布局并统计 115 个区间各自的标签数, 再从训练数据随机抽取完全相同的逐区间数量, 总数保持 23,720。两种方法共享验证标签、初始化和批次; 两种布局的区间集合与计数一致, 标签在行程中的位置分布不同。

表IV中, 本文方法在前缀和匹配随机布局下的 MAE 分别为 50.121 和 50.397 秒, 直接预测为 50.472 和 51.374 秒。随机改变标签位置没有恢复到更广区间覆盖时约 29 秒的水平, 削弱了将全部退化归因于前段位置的解释。该控制只使用一组标签布局, 行程和上下文分布尚未完全配平, 匹配随机的三次训练均在末步选模。该结果尚不足以确定位置或覆盖的独立贡献。

F. 修正机制与消融

修正幅度和加权中心化的比较采用固定 $\rho = 0.45$ 的 10% 训练/验证设置, 每组布局进行三次配对初始化 (表V)。该控制沿用 240 步训练协议, 与表II中的验证选参、960 步主比较分开报告。加权中心化下, $\rho = 0.10$ 、0.25 和 0.45 的 MAE 分别为 28.849、28.677 和 28.633 秒, RMSE 分别为 56.063、55.503 和 54.930 秒; $\rho = 0.25$ 的 Prefix50 最低, 因此没有一个幅度在所有指标上都占优。

去掉式(5)中的加权中心化, 直接令 $r_i = b_i + \rho b_i \tanh z_i$, 再执行相同总时长缩放。令 $m = \sum_j p_j \tanh z_j$, 这一变体的输出可写为

$$\hat{t}_i^{\text{unc}} = T p_i \left[1 + \frac{\rho (\tanh z_i - m)}{1 + \rho m} \right]. \quad (15)$$

相对于式(9), 缩放同时改变了有效修正幅度。因此, 该比较检验的是两种参数化, 不能分离中心化的独立作用。无加权中心化的 MAE 为 28.632 秒, 与固定 $\rho = 0.45$ 中心化控制的 28.633 秒基本相同。图3(b)-(d) 的配对差值显示指标与运行间存在波动, 现有证据没有显示加权零和中心化的精度优势。它保证修正不改变基础时间之和, 局部估计是否准确则仍取决于学到的分配。

表VI汇总三组 10% 训练/验证标签布局和每组的三次配对初始化, 每个条件共九次观测。关闭行程修正后, MAE 由 28.633 升至 29.038 秒, 九组配对比较均变差。该固定

TABLE II

ASTANA 开发集误差: 2,182 趟、87,715 段。除确定性均匀分配外, 数值为均值 $\pm$ 样本标准差。神经方法及固定权重组合各九次运行; 同段均值、NNLS 和 ExtraTrees 各覆盖三个标签布局。

预算	方法	MAE	RMSE	WAPE (%)	Prefix50	高贡献 10% MAE	长段 MAE
1%	均匀分配	54.28	87.17	58.54	276.78	182.45	338.02
1%	同段均值	31.50 $\pm$ 0.56	59.24 $\pm$ 0.88	33.96 $\pm$ 0.61	159.41 $\pm$ 4.72	92.90 $\pm$ 1.13	172.37 $\pm$ 6.11
1%	NNLS-Ridge	32.15 $\pm$ 0.58	60.95 $\pm$ 0.78	34.67 $\pm$ 0.63	167.09 $\pm$ 6.76	93.62 $\pm$ 0.93	172.18 $\pm$ 6.20
1%	ExtraTrees	32.47 $\pm$ 0.12	61.95 $\pm$ 0.58	35.01 $\pm$ 0.13	161.53 $\pm$ 3.92	98.80 $\pm$ 0.93	184.85 $\pm$ 3.94
1%	Direct prediction	33.19 $\pm$ 0.60	60.34 $\pm$ 0.86	35.79 $\pm$ 0.65	157.99 $\pm$ 4.73	95.17 $\pm$ 2.30	177.43 $\pm$ 5.68
1%	Ours	32.61 $\pm$ 0.28	60.68 $\pm$ 0.62	35.16 $\pm$ 0.30	156.04 $\pm$ 4.48	95.69 $\pm$ 2.65	183.25 $\pm$ 7.16
1%	Ours + Direct ($\alpha = 0.5$)	31.79 $\pm$ 0.26	58.80 $\pm$ 0.50	34.27 $\pm$ 0.28	151.72 $\pm$ 5.06	92.83 $\pm$ 2.23	177.33 $\pm$ 6.24
5%	均匀分配	54.28	87.17	58.54	276.78	182.45	338.02
5%	同段均值	29.99 $\pm$ 0.06	56.97 $\pm$ 0.10	32.34 $\pm$ 0.06	156.07 $\pm$ 2.84	88.98 $\pm$ 0.92	169.82 $\pm$ 4.07
5%	NNLS-Ridge	30.43 $\pm$ 0.05	58.06 $\pm$ 0.13	32.81 $\pm$ 0.06	163.04 $\pm$ 3.70	89.55 $\pm$ 0.87	170.01 $\pm$ 4.06
5%	ExtraTrees	29.70 $\pm$ 0.30	58.17 $\pm$ 0.97	32.02 $\pm$ 0.32	147.19 $\pm$ 2.76	92.60 $\pm$ 1.79	181.86 $\pm$ 4.64
5%	Direct prediction	29.46 $\pm$ 0.33	56.12 $\pm$ 0.91	31.76 $\pm$ 0.36	148.30 $\pm$ 4.96	87.44 $\pm$ 2.33	164.37 $\pm$ 7.44
5%	Ours	29.38 $\pm$ 0.13	57.05 $\pm$ 0.38	31.68 $\pm$ 0.14	148.35 $\pm$ 2.44	88.32 $\pm$ 1.53	171.22 $\pm$ 4.06
5%	Ours + Direct ($\alpha = 0.5$)	28.78 $\pm$ 0.16	55.47 $\pm$ 0.46	31.04 $\pm$ 0.17	145.18 $\pm$ 2.71	86.13 $\pm$ 1.72	165.47 $\pm$ 5.79
10%	均匀分配	54.28	87.17	58.54	276.78	182.45	338.02
10%	同段均值	29.85 $\pm$ 0.10	56.86 $\pm$ 0.50	32.19 $\pm$ 0.10	155.72 $\pm$ 1.10	88.54 $\pm$ 0.10	170.86 $\pm$ 3.21
10%	NNLS-Ridge	30.21 $\pm$ 0.05	57.57 $\pm$ 0.61	32.58 $\pm$ 0.05	162.35 $\pm$ 1.72	88.89 $\pm$ 0.11	170.88 $\pm$ 3.23
10%	ExtraTrees	29.03 $\pm$ 0.18	56.70 $\pm$ 0.53	31.30 $\pm$ 0.19	141.88 $\pm$ 2.10	89.96 $\pm$ 1.21	176.56 $\pm$ 3.97
10%	Direct prediction	28.48 $\pm$ 0.14	54.63 $\pm$ 0.76	30.71 $\pm$ 0.15	143.01 $\pm$ 4.08	83.64 $\pm$ 1.03	157.80 $\pm$ 3.62
10%	Ours	28.78 $\pm$ 0.16	55.52 $\pm$ 0.32	31.03 $\pm$ 0.17	144.64 $\pm$ 2.40	85.50 $\pm$ 0.67	166.07 $\pm$ 3.30
10%	Ours + Direct ($\alpha = 0.5$)	28.06 $\pm$ 0.10	53.99 $\pm$ 0.34	30.26 $\pm$ 0.11	140.84 $\pm$ 2.59	82.87 $\pm$ 0.61	159.39 $\pm$ 3.30




Fig. 2. 三个标签布局下相对直接预测的开发集 MAE 差。负值表示误差较低。神经方法先对每个布局下的三次配对初始化取均值; 同段均值和 NNLS 与对应布局的直接预测均值比较, ExtraTrees 与同布局 seed 42 的直接预测配对。点表示各布局, 横线为布局均值及样本标准差。

TABLE III

同一三组标签布局与三次初始化下 Ours 减直接预测的配对 MAE 差。负值表示 Ours 误差较低; 标准差按九组配对运行计算。

预算	平均差值 (秒)	标准差 (秒)	Ours 胜出数
1%	-0.579	0.624	8/9
5%	-0.075	0.353	6/9
10%	+0.295	0.169	0/9

$\rho = 0.45$ 控制表明修正在相同结构内改善了基础估计, 但不能证明验证选参后的 Ours 优于直接预测。

联合打乱日历字段保留了各划分内的字段组合, 却破坏其与行程的对应, MAE 升至 29.010 秒, 九组配对均高于该固定 $\rho = 0.45$ 控制。直接移除日历字段的 MAE 略低, 为 28.570 秒, 但 RMSE 和 Prefix50 更高。错配信息与缺少信息的影响不同, 现有结果不能证明日历字段不可缺少; 两个分支均使用日历上下文, 修正收益也不能全部归于某

一时间因素。

Singapore 辅助实验比较前缀损失的归一化方式。在相同完整标签设置下, 包含填充位置、仅计有效位置和不使用前缀目标的本文方法 MAE 分别为 19.518、19.445 和 19.490 秒; 仅计有效位置的直接预测为 19.545 秒。有效位置归一化在三次配对中均略低于对应直接预测和无前缀版本, 但长区间误差高于包含填充位置的版本。总体与长区间误差的变化不同; 该实验使用完整标签, 与 Astana 稀疏监督条件不同。

G. 逐区间案例与运行效率

图4展示相同总时长下的局部误差。两例分别含 44 段和 40 段, Ours 与直接预测 MAE 分别为 25.997/26.486 和 43.178/43.521 秒。部分区间的误差由同一行程中的其他区间补偿, 因此总时长一致并不保证局部分配准确。

效率测量使用同一 RTX 4090 D、float32 和 256 趟批次, 进行 10 次预热与 30 次同步计时。两种方法均实例化

TABLE IV

同标签总数、身份及每身份标签数量的布局控制：三次初始化、有限验证标签；误差单位为秒。粗体表示各可比组内的最低误差。

布局	方法	MAE	Prefix50
前 20% 标签	Ours	50.121 $\pm$ 0.938	318.01
前 20% 标签	直接预测	50.472 $\pm$ 0.549	326.46
身份计数匹配随机	Ours	50.397 $\pm$ 0.816	348.30
身份计数匹配随机	直接预测	51.374 $\pm$ 0.609	362.85

TABLE V

单独的固定 $\rho = 0.45$ 、240 步修正控制：三个 10% 训练/验证标签布局，每个布局三次配对初始化。误差单位为秒，报告均值与样本标准差。无加权中心化后的缩放也改变有效幅度。粗体表示各可比组内的最低误差。

变体	ρ	MAE	RMSE	Prefix50
加权中心化	0.10	28.849 $\pm$ 0.189	56.063 $\pm$ 0.328	145.34
加权中心化	0.25	28.677 $\pm$ 0.184	55.503 $\pm$ 0.353	143.64
加权中心化 (固定 ρ 控制)	0.45	28.633 $\pm$ 0.239	54.930 $\pm$ 0.401	145.26
无加权中心化	0.45	28.632 $\pm$ 0.218	55.030 $\pm$ 0.227	143.94

TABLE VI

统一有限训练与验证协议的消融：一组 10% 掩码、三次初始化；误差单位为秒。粗体表示各可比组内的最低误差。

变体	MAE	Prefix50
Ours	28.709 $\pm$ 0.396	144.27
关闭修正	29.011 $\pm$ 0.170	144.66
去日历特征	28.588 $\pm$ 0.132	148.43
打乱日历特征	29.033 $\pm$ 0.153	151.04

195,079 个参数，实际计算路径不同；前向延迟的中位数与四分位范围见补充材料。计时包含网络前向与总时长缩放，不含数据读取和主机传输。

H. 补充评价

表VII报告另一个 Singapore 已知总时长对比，包含 14,933 个 OD 和 295,318 个区间，目标定义与 Astana 不同。common-visible 方法不使用同段历史标签；strict-past 参考方法使用此前行程标签，单独列示。Ours 沿用相同分配结构，但使用完整局部标签、时长加权和含填充位置的前缀归一化，与 Astana 稀疏标签协议不同。MixTTE、DutyTTE 和 TriDGNNet 为同任务适配 [6], [11], [12]，参数数量和训练预算未配平；设置细节见补充材料。结果仅作描述性比较，不构成独立测试。

排除训练及验证中出现过的日期后，2,060 趟、82,783 段的 10% Ours 与直接预测 MAE 为 28.526 和 28.456 秒。未见完整有序路线的子集含 446 趟、17,164 段，两者 MAE 为 35.963 和 35.315 秒。路线组合变化伴随更高误差，但完整路线未见并不等于其中各区间都未见。

补充材料报告七档总时长偏差及训练预算检查。ProBETA 适配模型由 960 延长到 3,840 步后，MAE 从 36.403 降至 32.876 秒；一次运行的最优验证点仍在末步，表明其表现受到训练预算影响。

Astana 总时长由局部标签求和得到，标签缺失通过人工遮蔽构造。本文报告的是开发集结果，不能估计未触碰测试集上的性能。要评价实际适用性与泛化能力，还需使用独立测量的行程总时长、其他城市数据及完整同任务分解基线。




Fig. 3. 消融的配对误差差值，正值表示误差增加。(a) 以 Ours 为参照，(b)–(d) 以加权中心化 $\rho = 0.45$ 为参照，(e)–(f) 以有效位置前缀目标为参照。空心点为配对运行，实心菱形与误差线为均值和样本标准差；Astana 每条件九组，Singapore 三组。

V. 结论

本文研究已知总时长下的分段运行时间估计，将同段观测形成的共享估计与当前行程的调整结合起来。基础分支利用区间身份和上下文，行程分支在有界范围内重新分配时间，最后按已知总时长缩放。输出由此保持非负且加和一致，但总时长约束本身不能保证各段准确。

同段均值在标签极少时仍有竞争力。Ours 的 MAE 点估计在 1% 和 5% 预算下低于直接预测，分别低 0.579 秒和 0.075 秒；在 10% 下则更高。九组配对运行中，Ours 分别在 8、6 和 0 组误差较低，且三个预算下的长区间 MAE 均

TABLE VII

SINGAPORE 完整标签对比: 14,933 趟 OD、295,318 个区间。无历史输入方法使用相同给定总时长; STRICT-PAST 参考额外使用较早行程标签。误差单位为秒; 学习型方法报告三次运行的均值与总体标准差。粗体为无历史输入组的最低误差。

方法	次数	MAE (s)	RMSE (s)	Prefix50 (s)
<i>common-visible</i> 方法				
本文方法 (完整标签)	3	19.286 ± 0.033	28.009 ± 0.070	54.938 ± 1.043
MixTTE 适配	3	25.760 ± 0.053	35.654 ± 0.171	66.292 ± 0.255
DutyTTE 适配	3	25.936 ± 0.075	35.823 ± 0.082	66.805 ± 0.515
TriDGNet 适配	3	26.100 ± 0.109	36.029 ± 0.117	66.782 ± 0.502
均匀精确投影	1	34.399	53.694	102.362
观测弦长精确投影	1	45.655	60.701	116.574
历史信息参考方法				
Strict-past direct	1	19.843	36.217	57.385




Fig. 4. 开发行程的区间时间及有符号误差。从一组 10% 标签下的配对运行中, 选取 Ours 行程 MAE 最接近中位数与 90% 分位数的案例。黑、蓝、橙曲线分别表示真实时间、Ours 和直接预测。

更高。验证集选出的 Ours+Direct 集成在 5% 和 10% 下取得最低平均 MAE, 但 1% 下同段均值仍更低; 该集成是独立预测器。现有开发集结果不能证明 Ours 具有一致优势。相同标签数量在不同区间覆盖下仍产生不同误差。仍需使用独立总时长、未触碰的外部评价集及其他城市数据, 判断该分配结构能否改善局部估计。

REFERENCES

- [1] B. Hellinga, P. Izadpanah, H. Takada, and L. Fu, “Decomposing travel times measured by probe-based traffic monitoring systems to individual road segments,” *Transportation Research Part C: Emerging Technologies*, vol. 16, no. 6, pp. 768–782, 2008.
- [2] A. Hofleitner and A. M. Bayen, “Optimal decomposition of travel times measured by probe vehicles using a statistical traffic flow model,” in *2011 14th International IEEE Conference on Intelligent Transportation Systems*, 2011, pp. 815–821.
- [3] K. Yin, W. Wang, X. B. Wang, and T. M. Adams, “Link travel time inference using entry/exit information of trips on a network,” *Transportation Research Part B: Methodological*, vol. 80, pp. 303–321, 2015.
- [4] T. Sun, K. Zhao, C. Zhang, M. Chen, and X. Yu, “PR-LTTE: Link travel time estimation based on path recovery from large-scale incomplete trip data,” *Information Sciences*, vol. 589, pp. 34–45, 2022.
- [5] D. Wang, J. Zhang, W. Cao, J. Li, and Y. Zheng, “When will you arrive? estimating travel time based on deep neural networks,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, no. 1, 2018, pp. 2500–2507.
- [6] X. Mao, Y. Lin, S. Guo, Y. Chen, X. Xian, H. Wen, Q. Xu, Y. Lin, and H. Wan, “DutyTTE: Deciphering uncertainty in origin-destination travel time estimation,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 39, no. 12, 2025, pp. 12 390–12 398.
- [7] C. Xu, Q. Wang, and L. Sun, “Link representation learning for probabilistic travel time estimation,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 26, no. 11, pp. 21 149–21 161, 2025. [Online]. Available: <https://doi.org/10.1109/TITS.2025.3590075>
- [8] Y. Zhang, N. Charoenphakdee, Z. Wu, and M. Sugiyama, “Learning from aggregate observations,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 7993–8005. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2020/file/5b0fa0e4c041548bb6289e15d865a696-Paper.pdf
- [9] S. L. Wickramasuriya, G. Athanasopoulos, and R. J. Hyndman, “Optimal forecast reconciliation for hierarchical and grouped time series through trace minimization,” *Journal of the American Statistical Association*, vol. 114, no. 526, pp. 804–819, 2019. [Online]. Available: <https://doi.org/10.1080/01621459.2018.1448825>
- [10] A. Mansurova, A. Mussina, S. Aubakirov, A. Nugumanova, and D. Yedilkhan, “From raw gps to gtfs: A real-world open dataset for bus travel time prediction,” Zenodo, 2025, published June 29, 2025; CC BY 4.0. [Online]. Available: <https://zenodo.org/records/15769359>
- [11] W. Jiang, J. Han, R. Han, and H. Liu, “MixTTE: Multi-level mixture-of-experts for scalable and adaptive travel time estimation,” in *Proceedings of the 32nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2026.
- [12] J. Zuo, Y. Yao, and Y. Zhang, “TriDGNet: Triple feature encoder-based dual granularity graph learning network for enhanced travel time estimation,” *IEEE Transactions on Intelligent Transportation Systems*, 2026.