

补充材料：分段运行时间估计的实验细节

I. 实验设置

主实验限制训练和检查点选择标签。本材料补充报告区间覆盖、完整标签前缀目标、训练预算及总时长敏感性的开发分析。

II. 匹配优化配置检查

另一组匹配对比采用由可见验证标签选择的优化配置(余弦退火、初始学习率 0.001、训练 960 步)，每个预算进行九组配对运行。它使用与主文相同的 Astana 开发行程，但对应另一组已拟合模型；这不是独立数据集复现，也不替代主文按预算选参的比较。1%、5%、10% 下，Ours 减直接预测的 MAE 差分别为 +0.005、+0.133 和 +0.148 秒。5,000 次行程聚类百分位 Bootstrap 以已拟合模型和标签布局为条件，仅反映开发行程抽样不确定性，不包含重新训练的不确定性。1% 区间包含零，5% 和 10% 区间为正。该条件区间不能证明跨开发划分的泛化能力。

III. 布局控制的逐次结果

两种布局均开放 23,720 个训练标签，覆盖相同 115 个区间，逐区间计数完全一致；验证开放 2,656 个标签。训练均为 240 步、学习率 0.003，配对初始化和批次顺序相同。表II报告三次重复的误差。匹配随机布局中，本文方法的最优验证点均为最后一步，结果因此与这一训练预算相关。

计数匹配控制了每个区间的标签数量，尚未配平标签所在的行程、时段和上下文。因此，它帮助排查位置与区间覆盖共同变化的影响，但不确定二者各自的因果贡献。

IV. SINGAPORE 前缀目标验证

比较使用 50,000 趟训练、5,000 趟检查点选择和 10,000 趟开发行程，局部标签完整，无额外历史输入。训练 240 步，每 24 步选择一次；网络、初始化、批次和时长权重相同，分别改变归一化分母、前缀系数或预测方式。计入填充位置时，分母包含有效行程结束后的零累计误差，会稀释前缀目标；有效位置归一化只统计真实区间。

表III报告均值与样本标准差，表IV报告逐次结果。有效位置归一化降低总体 MAE，但长段 MAE 由 93.069 升至 96.582 秒；无前缀版本为 97.566 秒。与无前缀相比，三次总体 MAE 分别减少 0.026、0.056 和 0.055 秒。前缀归一化对不同误差指标的作用并不一致。

V. SINGAPORE COMMON-VISIBLE 对比

该 Singapore 已知总时长对比包含 14,933 个 OD 和 295,318 个区间，与前缀目标实验及 Astana 实验不同。common-visible 方法使用相同给定 OD 总时长，不使用同段历史标签；strict-past 参考方法使用严格早于当前行程的标签，因信息条件不同而单独列示。本文方法采用与主文相同的有界重新分配结构，使用 15 项输入特征、完整局部标签、时长加权 Huber 和前缀目标。主文对比表使用包含填充位置的前缀分母；有效位置版本另在前缀实验中报

告。网络宽度 64、两层 Transformer、四个注意力头，批次 2,048，训练 240 步，学习率 0.003，前缀系数 0.35。本文分配器和学习型适配方法报告三个随机种子的均值与总体标准差；确定性基线为单次结果。MixTTE、DutyTTE 和 TriDGNet [1]–[3] 是同任务适配而非原论文完整复现，参数量和训练预算未配平。给定总时长由标签构造，且可能不同于局部区间标签之和，因此误差表示给定总量下的分配结果，不代表恢复独立测得的总时间。该评估组仅作描述性比较，不构成独立测试。

VI. 训练预算检查

ProbETA 适配模型采用作者实现 [4]，以每步 256 个可见单区间抽样的高斯似然训练，学习率 0.003，使用 Adam、10% 训练标签和完整 26,561 个检查点选择标签，每 240 步选择一次。它与主文的行程批次、有限检查点选择标签及 Huber 目标不同，故单独报告。

训练预算从 960 扩到 3,840 步，并保持初始化和前 960 步抽样相同，评估 MAE 由 36.403 降至 32.876 秒。最优验证点分别为 3,600、3,840 和 3,360 步(表V)。其中一次位于最后一步，说明较短预算限制了适配模型的表现，且延长后的优化充分性仍需检验。

表VI的 1,920 步检查采用每步 256 个可见单标签抽样和完整验证标签；本文方法及仅身份输入版本学习率为 0.001，直接预测为 0.003。最优点均早于最后一步，之后验证误差回升。由于抽样方式、验证标签和学习率不同，该结果用于分析训练过程，不与主表合并排序。

VII. 完整验证标签与总时长敏感性

表VII和VIII使用完整 26,561 个验证标签，分别考察标签布局和日历修正分支。前缀布局减少区间覆盖，移动连续遮挡保留更多区间；主文进一步固定逐区间计数。完整验证与有限验证的标签成本不同，结果分别解释。

总时长敏感性分析保持十八个 10% 模型的参数不变，将输入改为 $T' = (1 + \epsilon)T$ ，在七档偏差下进行 126 次评价。负 5% 偏差时，本文方法 MAE 为 28.199 秒，低于精确总时长时的误差，但输出不再符合真实总时长。三角不等式给出 $\sum_i |\hat{t}_i - t_i| \geq |\epsilon|T$ ，相同相对偏差下 WAPE 至少为 $|\epsilon|$ 。该实验检验统一尺度偏差，未模拟随机测量误差。

VIII. 额外历史与效率

历史扩展从训练分区选取最多 20,000 趟查询前已完成、区间匹配的行程。这些记录可以位于 50,000 趟优化样本之外，因而提供额外标签。表X固定历史输入，比较缩放前同段对数时长目标的系数 0 和 0.15；该实验采用计入填充位置的前缀归一化，结果与无历史辅助实验分别报告。

计时环境为 RTX 4090 D、PyTorch 2.5.1+cu121，固定保存的 10% 主模型及 256 趟输入批次。float32 前向、10 次预热、30 次同步测量；中位数与四分位范围见表XI。计时不含数据读取、传输和训练。

TABLE I

ASTANA 开发集上的另一组匹配优化配置检查。MAE 单位为秒；运行结果为九组配对模型的均值 $\pm$ 样本标准差。区间由行程重采样得到，并以已拟合模型和标签布局为条件。

预算	Ours MAE	Direct MAE	差值	行程 Bootstrap 95% 区间
1%	33.191 $\pm$ 0.278	33.186 $\pm$ 0.605	+0.005	[−0.077, 0.088]
5%	29.590 $\pm$ 0.219	29.457 $\pm$ 0.333	+0.133	[0.063, 0.202]
10%	28.629 $\pm$ 0.153	28.481 $\pm$ 0.140	+0.148	[0.074, 0.223]

TABLE II

身份计数匹配控制的逐初始化重复 MAE (秒)。P 为前缀布局，R 为匹配随机布局。

重复	P Ours	P 直接	R Ours	R 直接
1	50.102	49.889	49.462	51.407
2	49.193	50.548	50.762	51.966
3	51.069	50.979	50.968	50.749

TABLE III

SINGAPORE 前缀归一化验证：完整训练与验证标签、三次初始化、无额外历史输入；误差单位为秒。粗体表示各可比组内的最低误差。

方法	MAE	Prefix50	长段 MAE
Ours: 分母包含填充	19.518 $\pm$ 0.057	55.86	93.07
Ours: 分母仅计有效位置	19.445 $\pm$ 0.115	55.09	96.58
Ours: 无前缀损失	19.490 $\pm$ 0.129	55.41	97.57
直接预测: 分母仅计有效位置	19.545 $\pm$ 0.096	55.56	96.81

TABLE IV

SINGAPORE 前缀验证的逐初始化重复 MAE (秒)。

重复	含填充分母	有效分母	无前缀	直接预测
1	19.513	19.341	19.367	19.441
2	19.577	19.569	19.624	19.632
3	19.465	19.424	19.480	19.562

REFERENCES

- [1] W. Jiang, J. Han, R. Han, and H. Liu, “MixTTE: Multi-level mixture-of-experts for scalable and adaptive travel time estimation,” in *Proceedings of the 32nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2026.
- [2] X. Mao, Y. Lin, S. Guo, Y. Chen, X. Xian, H. Wen, Q. Xu, Y. Lin, and H. Wan, “DutyTTE: Deciphering uncertainty in origin-destination travel time estimation,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 39, no. 12, 2025, pp. 12 390–12 398.
- [3] J. Zuo, Y. Yao, and Y. Zhang, “TriDGNet: Triple feature encoder-based dual granularity graph learning network for enhanced travel time estimation,” *IEEE Transactions on Intelligent Transportation Systems*, 2026.
- [4] C. Xu, Q. Wang, and L. Sun, “Link representation learning for probabilistic travel time estimation,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 26, no. 11, pp. 21 149–21 161, 2025. [Online]. Available: <https://doi.org/10.1109/TITS.2025.3590075>

TABLE V
PROBETA 改造模型的 3,840 步固定预算检查；误差单位为秒。

重复	选中步数	评估 MAE	末步验证 MAE
1	3600	32.552	31.108
2	3840	32.999	31.355
3	3360	33.078	32.785

TABLE VI

1,920 步训练检查：一个 10% 训练掩码、完整验证标签。各方法学习率不同，本表不用于方法排名。选中步数按重复 1/2/3 排列；MAE 单位为秒。

方法	MAE	选中步数
Ours	28.893	1200/1200/1680
直接预测	28.620	1440/480/1680
仅身份输入	28.946	1440/960/1200

TABLE VII

标签布局控制：23,720 个训练标签、完整验证标签、三次初始化。身份数为可见区间身份；后段 MAE 评价各行程约后 80% 位置（秒）。粗体表示各可比组内的最低误差。

布局	方法	身份数	总体 MAE	后段 MAE
随机	Ours	301	28.522 ± 0.216	27.776
随机	直接预测	301	28.353 ± 0.212	27.641
前 20%	Ours	115	50.121 ± 0.938	55.375
前 20%	直接预测	115	50.472 ± 0.549	55.818
移动遮挡	Ours	310	28.774 ± 0.116	28.348
移动遮挡	直接预测	310	28.810 ± 0.013	28.401

TABLE VIII

日历特征与修正消融：一个 10% 训练掩码、完整验证标签、三次初始化；误差单位为秒。粗体表示各可比组内的最低误差。

变体	MAE	Prefix50
关闭修正	29.035 ± 0.175	145.17
去日历特征	28.612 ± 0.160	150.74
Ours	28.522 ± 0.216	141.74
打乱日历特征	29.082 ± 0.298	157.30

TABLE IX

冻结 10% 模型的总量偏差敏感性情景，每种方法九次运行。MAE 单位为秒，WAPE 单位为百分比；不同偏差情景不作排名。

偏差	Ours MAE	直接 MAE	Ours WAPE	直接 WAPE
-10%	28.361	28.337	30.58	30.56
-5%	28.199	28.149	30.41	30.35
-1%	28.500	28.425	30.73	30.65
+0%	28.633	28.551	30.87	30.79
+1%	28.788	28.699	31.04	30.95
+5%	29.629	29.507	31.95	31.82
+10%	31.150	30.981	33.59	33.41

TABLE X

SINGAPORE 历史输入控制，两种方法使用相同的严格过去信息源。单位为秒；三次初始化的均值与样本标准差。粗体表示各可比组内的最低误差。

方法	MAE	Prefix50	长段 MAE
历史输入与损失	19.304 ± 0.116	54.603 ± 0.436	92.217 ± 2.536
仅历史输入	19.324 ± 0.106	54.606 ± 0.429	93.736 ± 2.335

TABLE XI

同设备 256 趟批次前向计时（毫秒），30 次重复。粗体表示最低中位数。

方法	中位数	四分位范围
Ours	6.040	[6.034, 6.043]
直接预测	5.450	[5.435, 5.469]